



Univerzitet u Novom Sadu

Fakultet tehničkih nauka

Principi prezentacije i prepoznavanje oblika
Generative Adversarial Networks (GAN) za generisanje slika LEGO figurica

Checkpoint 3
Analiza dobijenih rezultata

Profesori: prof. dr Marko Arsenović,
prof. dr Anderla Andraš
Asistent: Sofija Đorđević

Student: Anđela Mrđa IT7-2022
Smjer: Inženjerstvo informacionih sistema

Novi Sad, februar 2026.

Sadržaj:

1. Opis sprovedenog eksperimenta.....	2
2. Odabir metrika i njihova interpretacija u kontekstu GAN-a.....	3
3. Analiza procesa treniranja i stabilnosti modela.....	3
3.1 Loss krive (train vs validation).....	3
3.2 Accuracy diskriminatora i adversarijalna ravnoteža.....	4
4. Test evaluacija diskriminatora.....	5
5. Kvalitativna analiza: vizuelni rezultati i latentni prostor.....	6
5.1 Poređenje realnih i generisanih slika.....	6
5.2 Interpolacija u latentnom prostoru.....	7
6. FID metrika i njeno značenje.....	7
7. Pokušaj poboljšanja: WGAN-GP.....	8
8. Zaključci i budući pravci rada.....	9

1. Opis sprovedenog eksperimenta

U ovom projektu implementiran je **DCGAN (Deep Convolutional Generative Adversarial Network)** sa ciljem generisanja sintetičkih slika LEGO minifigura. Korišćen je augmentirani dataset **LEGO_GAN_AUG**, pripremljen u Kontrolnoj tački 2, koji sadrži približno **2000 slika** raspoređenih u četiri tematske klase (*Harry Potter*, *Jurassic World*, *Marvel* i *Star Wars*), sa približno jednakim brojem uzoraka po klasi. Slike su skalirane na rezoluciju **64×64 piksela** i normalizovane u opseg **[-1, 1]**, što je standardna praksa kod GAN modela sa Tanh izlaznom aktivacijom (*Slika 1*).

DCGAN arhitektura sastoji se od dva modela koji se treniraju adversarijalno:

- **Generator**, koji mapira latentni vektor šuma u prostor slika,
- **Diskriminator**, koji pokušava da razlikuje realne slike iz dataseta od generisanih.

Za razliku od klasičnih supervised modela, cilj ovog sistema nije minimizacija jedne loss funkcije, već postizanje **ravnoteže između dva suprotstavljena procesa**. U tom smislu, kvalitet modela se ne procenjuje samo na osnovu loss vrijednosti, već kroz kombinaciju stabilnosti treninga, ponašanja diskriminatora, kvantitativnih metrika i vizuelnih rezultata.

Uzorci pravih slika iz train dataseta



Slika 1: Uzorci pravih slika iz augmentovanog data seta LEGO_GAN_AUG

2. Odabir metrika i njihova interpretacija u kontekstu GAN-a

Evaluacija GAN modela zahtijeva drugačiji pristup u odnosu na klasične klasifikacione ili regresione zadatke. Metrike poput accuracy ili loss nemaju isto značenje, jer **idealno treniran GAN ne treba da ima savršenog diskriminatora**.

Zbog toga su u ovom radu korišćene sljedeće grupe metrika:

- **Generator i Discriminator loss (train/validation)** – koriste se za praćenje stabilnosti treninga i detekciju kolapsa ili divergencije.
- **Accuracy diskriminatora (Real/Fake)** – u GAN kontekstu, vrijednosti bliske 50% ukazuju na ravnotežu između generatora i diskriminatora.
- **Test klasifikacione metrike (Accuracy, Precision, Recall, F1, ROC-AUC)** – koriste se za procjenu diskriminativne moći na test skupu, ali se interpretiraju drugačije nego u supervised učenju.

- **FID (Fréchet Inception Distance)** – kvantitativna metrika sličnosti distribucija realnih i generisanih slika u prostoru dubokih feature-a.
- **Latentna interpolacija** – kvalitativna analiza strukture i kontinuiteta latentnog prostora.

Ovakav skup metrika omogućava **višeslojnu evaluaciju**, gdje se nijedan pojedinačni broj ne posmatra izolovano.

3. Analiza procesa treniranja i stabilnosti modela

3.1 Loss krive (train vs validation)


Tokom treninga uočena je **ciklična dinamika**, karakteristična za GAN modele: u pojedinim fazama Diskriminator privremeno dominira, nakon čega Generator uspijeva da se oporavi i ponovo smanji razliku. Ovakvo ponašanje je očekivano i ne predstavlja problem dok se model na kraju stabilizuje.

U završnoj fazi treniranja (poslednjih ~60 epoha) train i validation loss vrijednosti ostaju bliske:


Generator loss: **0.5266 (train) / 0.5099 (val)**

Discriminator loss: **1.4056 (train) / 1.4749 (val)**

Mala razlika između trening i validacionih krivih ($\approx 3\text{--}5\%$) ukazuje da **nema izraženog overfitting-a**, te da model uči opštu distribuciju podataka umjesto memorisanja pojedinačnih uzoraka (*Slika 3*).



Slika 2 – Train i Validation loss kroz epohe



Slika 2 – Generator i Discriminator loss tokom treninga i validacije


3.2 Accuracy diskriminatora i adversarijalna ravnoteža

U klasičnim klasifikacionim problemima visoka accuracy predstavlja dobar rezultat. Međutim, kod GAN-a visoka accuracy diskriminatora znači da Generator ne proizvodi uvjerljive uzorke. Zbog toga je cilj postići accuracy blisku nasumičnom pogađanju.


U završnoj fazi treninga dobijene su sljedeće vrijednosti:

- D Accuracy (Real): **52.40%**
- D Accuracy (Fake): **55.01%**
- Ukupna accuracy: **53.71%**

Ovi rezultati ukazuju da je postignuto stanje blisko **adversarijalnoj ravnoteži**, gdje Diskriminator više ne može pouzdano razlikovati realne i generisane slike (Slika 4).



Slika 4 - Accuracy diskriminatora (Real/Fake) kroz epohe



Slika 5 - Progresija generisanih slika kroz faze treninga

4. Test evaluacija diskriminatora


Kako bi se kvantitativno potvrdila sposobnost Generatora da proizvodi uvjerljive slike, Diskriminator je evaluiran na test skupu kao binarni klasifikator. Dobijeni rezultati su:

- Accuracy: **48.71%**
- Precision: **0.4845**
- Recall: **0.9367**
- F1-score: **0.6386**
- ROC-AUC: **0.6416**

Niska ukupna tačnost i relativno visok recall za real klasu ukazuju da Diskriminator često pogrešno klasifikuje generisane slike kao realne. U GAN kontekstu, ovo predstavlja poželjan ishod, jer implicira da Generator proizvodi uzorke koji su teško razlikljivi od stvarnih.

Metrika	Vrijednost	Interpretacija u kontekstu GAN-a
Accuracy	48.71%	D pogađa gore od bacanja novčića – slike nerazlučive
Precision	0.4845	Kad D kaže "pravo", u pola slučajeva griješi
Recall	0.9367	D skoro sve proglašava "pravim" jer su lažne ubjedljive
F1-Score	0.6386	Umjeren – D se aktivno muči da razlikuje
ROC-AUC	0.6416	Blizu 0.5 – skoro nema moći razlikovanja

Tabela 1 - Interpretacija rezultata na test skupu




Slika 6 - Matrica konfuzije (Confusion matrix)

5. Kvalitativna analiza: vizuelni rezultati i latentni prostor

5.1 Poređenje realnih i generisanih slika


Vizuelna inspekcija pokazuje da Generator uspijeva da nauči **globalne karakteristike** slika (centralna figura, osnovne boje i raspored), ali da finiji detalji i teksture ostaju ograničeni. Ovakav rezultat je u skladu sa relativno visokim FID skorom i ograničenjima dataseta.



Slika 7 - Poređenje pravih i generisanih slika

5.2 Interpolacija u latentnom prostoru

Interpolacija između dvije latentne tačke pokazuje glatke i postepene promjene u generisanim slikama, bez naglih diskontinuiteta ili kolapsa strukture (*Slika 8*). Ovo ukazuje da latentni prostor Generatora ima **kontinuiranu i smisleno organizovanu strukturu**, što sugerise da model uči distribuciju podataka, a ne memorisane uzorke.



Slika 8 - Interpolacija u latentnom prostoru

6. FID metrika i njeno značenje

Izračunati **FID score iznosi 199.33**, što ukazuje da distribucija generisanih slika i dalje značajno odstupa od realne distribucije. Iako je ova vrijednost visoka u apsolutnom smislu, ona je očekivana za dataset ove veličine i raznolikosti. U ovom radu FID se koristi prvenstveno kao **relativna metrika**, za poređenje različitih eksperimenata, a ne kao apsolutni pokazatelj kvaliteta. Rezultati dobijenih FID score vrijednosti u zavisnosti od veličine dataseta se mogu vidjeti u tabeli ispod (*Tabela 2*).

Dobijeni FID Score: 199.33		
FID raspon	Kvalitet	Tipičan kontekst
< 10	Izvanredan	StyleGAN2, milioni slika
10–50	Vrlo dobar	Veliki dataseti (50k+ slika)
50–100	Dobar	Srednji dataseti
100–200	Umjeren	Mali dataseti – naš slučaj
200–300	Slab	Nedovoljno treniran model
300+	Loš	Model ne funkcioniše


Tabela 2 - Dobijeni FID score

7. Pokušaj poboljšanja: WGAN-GP

Na osnovu teorijskih prednosti Wasserstein GAN modela, implementiran je i **WGAN-GP** kao pokušaj poboljšanja stabilnosti i kvaliteta generisanih slika. Očekivanje je bilo da Wasserstein loss i gradient penalty obezbijede stabilnije gradijente i bolju konvergenciju.

Međutim, eksperimentalni rezultati nisu pokazali poboljšanje. Tokom treninga Critic je pokazivao ekstremno neuravnoteženo ponašanje ($\text{Accuracy_real} \approx 100\%$, $\text{Accuracy_fake} \approx 0\%$), što

ukazuje na degenerisanu adversarijalnu dinamiku. Dodatno, FID skor se pogoršao na **268.78**, a vizuelni kvalitet generisanih slika bio je lošiji u odnosu na DCGAN.



Slika 8 – Primjeri slika generisanih WGAN-GP modelom

SUMARNA TABELA REZULTATA				
Metrika	Vrednost			
Generator Loss (finalna)	-118.9211			
Discriminator Loss (finalna)	-0.9133			
Val Generator Loss (finalna)	-118.5713			
Val Discriminator Loss (finalna)	-0.6579			
D Accuracy (Real)	100.00%			
D Accuracy (Fake)	0.00%			
D Accuracy (Ukupna)	50.00%			
Test Accuracy	48.39%			
Test Precision	0.4839			
Test Recall	1.0000			
Test F1-Score	0.6522			
Test ROC-AUC	0.5541			
FID Score	268.78			
Epoha	G Loss	D Loss	Acc Real	Acc Fake
1	-11.6685	34.3645	91.35%	0.65%
126	-28.6183	0.1978	100.00%	0.00%
251	-60.8537	-0.5267	100.00%	0.00%
376	-92.6892	-0.4172	100.00%	0.00%
500	-118.9211	-0.9133	100.00%	0.00%

Tabela 3 – Sumarna tabela rezultata WGAN-GP

Metrika / Aspekt	DCGAN (finalni model)	WGAN-GP (pokušaj poboljšanja)
Tip modela	Klasični DCGAN	Wasserstein GAN sa Gradient Penalty
Loss funkcija	Binary Cross-Entropy	Wasserstein loss + GP
Stabilnost treninga	Stabilan u završnoj fazi	Numerički stabilan, ali degenerisan
Dinamika treninga	Ciklična, sa završnim balansom	Dominacija Critic-a kroz cijeli trening
D / Critic Accuracy (Real)	~52%	~100%
D / Critic Accuracy (Fake)	~55%	~0%
Ukupna Accuracy (train)	~54%	~50% (trivijalna)
Test Accuracy	48.7%	48.4%
Test Precision	0.48	0.48
Test Recall	0.94	1.00
Test F1-score	0.64	0.65
Test ROC-AUC	0.64	0.55
FID Score ↓	199.33	268.78
Vizuelni kvalitet	Prepoznatljiva globalna struktura	Strukturalno degradirane slike
Latentni prostor	Kontinuiran i smislen	Slabo iskorišten
Adversarijalni balans	Postignut u završnoj fazi	Nije postignut
Konačna odluka	Zadržan kao finalni model	Odbačen

Tabela 4 – Poređenje DCGAN i WGAN-GP modela

8. Zaključci i budući pravci rada

Na osnovu sprovedenih eksperimenata može se zaključiti da je **DCGAN model postigao stabilan trening i prihvatljive rezultate u okviru ograničenja dataseta**, dok WGAN-GP u ovoj postavci nije dao očekivano poboljšanje. Rezultati jasno ukazuju da veličina i kvalitet dataseta predstavljaju ključni faktor za uspjeh GAN modela.

Budući rad može uključiti veći i homogeniji dataset, uslovne GAN arhitekture, veće rezolucije i savremenije modele poput StyleGAN-a, što bi vjerovatno dovelo do značajnog poboljšanja vizuelnog kvaliteta generisanih slika.