



Univerzitet u Novom Sadu

Fakultet tehničkih nauka

Principi prezentacije i prepoznavanje oblika

Generative Adversarial Networks (GAN) za generisanje slika

LEGO figurica

Profesori: prof. dr Marko Arsenović,

prof. dr Anderla Andraš

Asistent: Sofija Đorđević

Student: Anđela Mrđa IT7-2022

Smjer: Inženjerstvo informacionih sistema

Novi Sad, januar 2026.

Sadržaj

1. Uvod.....	3
2. Osnovni pojmovi i teorijska osnova GAN-a	4
3. Pregled istraživanja o primjeni GAN modela u generisanju slika	6
4. Najčešće korišćeni algoritmi i modeli generativnih adversarijalnih mreža	8
5. Skupovi podataka, metrike i ograničenja	10
6. Vizija i komentar.....	10
7. Opis sprovedenog eksperimenta.....	12
8. Odabir metrika i njihova interpretacija u kontekstu GAN-a	13
9. Analiza procesa treniranja i stabilnosti modela	13
10. Test evaluacija diskriminatora.....	15
11. Kvalitativna analiza: vizuelni rezultati i latentni prostor	17
12. FID metrika i njeno značenje	18
13. Analiza po klasama i ograničenja modela.....	18
14. Pokušaj poboljšanja: WGAN-GP.....	19
15. Zaključak i budući pravci rada	21
16. Literatura	22

1. Uvod

Razvoj dubokog učenja doveo je do značajnog napretka u oblasti vizuelne percepcije računarskih sistema, naročito u zadacima kao što su klasifikacija, detekcija i segmentacija slika. Pored ovih zadataka, sve veću pažnju privlače generativni problemi, čiji je cilj stvaranje novih podataka koji su statistički i vizuelno slični postojećim uzorcima. Generisanje realističnih slika predstavlja jedan od najsloženijih problema u ovoj oblasti, budući da zahtijeva razumijevanje strukture, teksture, boje i međusobnih odnosa unutar vizuelnog sadržaja.

Generativni modeli imaju široku primjenu u savremenim sistemima vještačke inteligencije. Oni se koriste za sintezu slika, proširenje skupova podataka (data augmentation), poboljšanje kvaliteta postojećih podataka, kao i u kreativnim i industrijskim oblastima, uključujući dizajn, animaciju i igre. Među različitim pristupima generativnom modelovanju, generativne adversarijalne mreže (GAN – *Generative Adversarial Networks*) izdvajaju se kao jedan od najuticajnijih i najuspješnijih modela za generisanje vizuelnog sadržaja visoke rezolucije i realističnog izgleda.

Kada govorimo o adversarijalnim mrežama, dolazimo do ideje o postojanju dva takmičarska neuronska modela - generatora i diskriminatora. Generator je dio mreže koji ima zadatak da proizvodi nove uzorke podataka, dok je uloga diskriminatora da razlikuje generisane uzorke od stvarnih podataka iz skupa za treniranje. Kroz čitav ovaj proces, oba modela se istovremeno unapređuju, što kao rezultat daje realističnije generisane podatke.

U ovom radu se razmatra primjena generativnih adversarijalnih mreža na problem generisanja slika LEGO figurica. LEGO figurice predstavljaju zanimljiv i moderan vizuelni domen zbog svoje velike raznolikosti u bojama, oblicima, pozama i dodatnim detaljima, kao i zbog jasne strukture objekata. Takav skup podataka omogućava istraživanje sposobnosti GAN modela da generišu koherentne i vizuelno uvjerljive slike objekata koji imaju prepoznatljivu formu, ali istovremeno i značajan stepen varijabilnosti.


Cilj prve faze projekta je proučavanje teorijskih osnova generativnih adversarijalnih mreža, kao i postojećih pristupa i varijanti ovih modela koje su do sada korišćene za generisanje slika. Poseban akcenat stavljen je na razumijevanje principa rada GAN arhitektura, tipičnih skupova podataka i metrika za evaluaciju kvaliteta generisanih slika. Ova teorijska osnova predstavlja temelj za kasnije faze projekta, u kojima će biti razmatrana implementacija modela i analiza dobijenih rezultata.

2. Osnovni pojmovi i teorijska osnova GAN-a

Generativni modeli predstavljaju klasu modela mašinskog učenja čiji je cilj učenje distribucije podataka, kako bi se na osnovu naučenog obrasca mogli generisati novi, prethodno neviđeni uzorci. Za razliku od drugih diskriminativnih modela (*klasifikacija, segmentacija, detekcija*) koji su usmjereni na razlikovanje ili klasifikovanje postojećih podataka, generativni modeli nastoje da opišu kako su podaci raspoređeni u prostoru osobina. Upravo ova sposobnost je ono što čini generativne mreže posebno pogodnim za zadatke koji uključuju sintezu teksta, govora, muzike, slika i drugih kompleksnih oblika podataka.

U formalnom smislu, generativni modeli nastoje da aproksimiraju zajedničku raspodjelu podataka i oznaka, označenu kao $p(X, Y)$, ili samo raspodjelu podataka $p(X)$ u slučajevima kada oznake nisu dostupne. Nasuprot tome, diskriminativni modeli uče uslovnu vjerovatnoću $p(Y | X)$, odnosno fokusirani su isključivo na predviđanje oznake na osnovu ulaznih podataka. Ova razlika nam govori da generativni modeli moraju naučiti znatno složeniju strukturu podataka, jer obuhvataju i međusobne zavisnosti između osobina, a ne samo granice razdvajanja između klasa.

Ilustracija razlike između generativnih i diskriminativnih modela prikazana je na slici (Slika 1), gdje diskriminativni model uči granicu razdvajanja između klasa, dok generativni model nastoji da modeluje raspodjelu podataka unutar svake klase.



Slika 1: Razlika između diskriminativnih i generativnih modela

Generativne adversarijalne mreže (GAN) predstavljaju specifičnu klasu generativnih modela, prvi put predstavljenu u radu Goodfellowa ¹ i saradnika. Osnovna ideja GAN

¹ I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville i Y. Bengio, "Generative Adversarial Networks," *Proceedings of the International Conference on Neural Information Processing Systems (NeurIPS)*, 2014, pp. 2672–2680.

arhitekture zasniva se na adversarijalnom učenju dva neuronska modela: **generatora** i **diskriminatora**.

Generator ima zadatak da proizvodi sintetičke uzorke koji podsjećaju na stvarne podatke iz skupa za treniranje, dok je diskriminator obučen da razlikuje stvarne podatke od onih koje je proizveo generator.

Tokom procesa učenja, generator i diskriminator se nalaze u stalnoj konkurenciji. Generator nastoji da proizvede uzorke koji će zavarati diskriminator, dok diskriminator pokušava da unaprijedi svoju sposobnost razlikovanja stvarnih i generisanih podataka. Ovakva postavka vodi ka situaciji u kojoj generator, ukoliko je proces učenja stabilan i uspješan, proizvodi sve realističnije uzorke koji se teško razlikuju od stvarnih podataka.

Proces treniranja GAN-a može se intuitivno objasniti kroz faze učenja. Na početku treniranja, generator proizvodi očigledno nerealistične uzorke, te diskriminator vrlo lako prepoznaje generisane podatke kao lažne (*Slika 2*).



Slika 2: Početak generisanja podataka

Kako treniranje napreduje, generator postepeno unapređuje kvalitet svojih izlaza, dok diskriminator postaje sve manje siguran u svoje odluke (*Slika 3*).




Slika 3: Generator počinje da generiše vjerodostojnije slike

U idealnom slučaju, dolazi se do ravnoteže u kojoj diskriminator više ne može pouzdano razlikovati stvarne i generisane uzorke (*Slika 4*).



Slika 4: Diskriminator ne može razlikovati generisanu sliku od stvarne

Cjelokupna arhitektura generativne adversarijalne mreže sastoji se od dva osnovna toka podataka. Prvi tok obuhvata stvarne podatke koji se uzorkuju iz skupa za treniranje i proslijeđuju diskriminatoru. Drugi tok započinje slučajnim ulazom, najčešće iz latentnog prostora, koji generator transformiše u sintetičke uzorke. I stvarni i generisani uzorci se zatim proslijeđuju diskriminatoru, čiji izlaz predstavlja procjenu vjerovatnoće da je ulazni uzorak stvaran. Povratna propagacija greške omogućava ažuriranje parametara oba modela tokom treniranja (Slika 5).



Slika 5: Cjelokupna arhitektura generativne adversarijalne mreže


Važno je naglasiti da su i generator i diskriminator najčešće realizovani kao **neuronske mreže** (*modeli mašinskog učenja inspirisani načinom rada bioloških neuronskih sistema*), te da njihova arhitektura može varirati u zavisnosti od tipa podataka i konkretne primjene. Ova fleksibilnost omogućava primjenu GAN modela ne samo na slike, već i na druge vrste podataka, uključujući vremenske serije, grafove i trodimenzionalne strukture. Međutim, upravo zbog složenosti zadatka modelovanja cjelokupne raspodjele podataka, generativni modeli, a naročito GAN-ovi, suočavaju se sa brojnim izazovima u pogledu stabilnosti treniranja i pokrivenosti modova podataka, što će biti detaljnije razmatrano u narednim poglavljima.

3. Pregled istraživanja o primjeni GAN modela u generisanju slika

Razvoj generativnih adversarijalnih mreža započinje radom Goodfellowa i saradnika iz 2014. godine, koji je uveo adversarijalni okvir učenja generativnih modela kroz istovremeno treniranje generatora i diskriminatora. Ovaj pristup je pokazao da se kompleksne distribucije podataka mogu implicitno naučiti bez eksplicitnog modelovanja vjerovatnoće, što je predstavljalo značajan iskorak u oblasti generativnog modelovanja.

Rani eksperimenti u ovoj oblasti fokusirali su se na relativno jednostavne skupove podataka, ali su jasno ukazali na potencijal GAN pristupa u sintezi vizuelnih sadržaja.

Kako su se istraživanja razvijala, fokus literature se pomjerao ka unapređenju stabilnosti treniranja i kvaliteta generisanih slika. Posebno značajan doprinos u tom kontekstu predstavlja uvođenje konvolucionih arhitektura u GAN modele (*Slika 6*), što je dovelo do boljeg iskorišćenja prostorne strukture slika i znatno realističnijih rezultata. Ovi radovi su pokazali da arhitektonski izbori imaju ključnu ulogu u uspješnosti GAN modela, te su postavili temelje za njihovu širu primjenu u zadacima obrade slika.



Slika 6: Uvođenje konvolucionih arhitektura u GAN modele

Paralelno sa arhitektonskim unapređenjima, veliki dio literature bavio se teorijskim i optimizacionim izazovima adversarijalnog učenja. Predloženi su različiti pristupi koji nastoje da obezbijede stabilniju dinamiku učenja i pouzdaniji signal za optimizaciju, čime se ublažavaju problemi poput nestabilnosti i oscilovanja tokom treniranja. Ovi radovi su doprinijeli boljem razumijevanju ponašanja GAN modela i omogućili njihovu primjenu na složenijim i raznovrsnijim skupovima podataka.

Sa razvojem stabilnijih GAN varijanti, istraživanja su se proširila i na širi spektar slikovnih zadataka. GAN-ovi su se afirmisali ne samo u sintezi slika „od nule“, već i u zadacima transformacije između vizuelnih domena, kao što su prevođenje slike u sliku, prenos stila i manipulacija vizuelnim atributima. Ovakvi pristupi su pokazali da GAN modeli mogu efikasno naučiti relacije između različitih domena čak i u uslovima ograničene ili neuparene obuke, što je značajno proširilo njihovu praktičnu upotrebljivost.

Napredak u kvalitetu generisanih slika dodatno je podstaknut arhitekturama koje omogućavaju finiju kontrolu procesa generisanja i bolju organizaciju latentnog prostora. Ovi modeli su demonstrirali da se razdvajanjem globalnih strukturalnih karakteristika od lokalnih detalja može postići veća raznovrsnost i viši perceptivni kvalitet generisanih

uzoraka. Takvi pristupi su naročito značajni za vizuelne domene u kojima je važno očuvati prepoznatljivu strukturu objekata, uz istovremeno generisanje novih varijacija.


U kontekstu ovog projekta, prethodna literatura jasno pokazuje da su GAN modeli posebno pogodni za probleme generisanja slika sa izraženom strukturom i vizuelnom raznolikošću. Iako su izazovi poput stabilnosti treniranja i pokrivenosti modova i dalje prisutni, dosadašnja istraživanja ukazuju da se pažljivim izborom arhitekture i pristupa treniranju mogu postići smisleni i vizuelno uvjerljivi rezultati. Ova saznanja predstavljaju teorijsku osnovu za dalju primjenu GAN modela na domen slika LEGO figurica, koji kombinuje jasnu strukturu objekata sa velikim brojem mogućih varijacija.

4. Najčešće korišćeni algoritmi i modeli generativnih adversarijalnih mreža

Nakon uvođenja osnovnog GAN okvira, istraživanja su se brzo usmjerila ka razvoju različitih varijanti i arhitektura koje nastoje da unaprijede kvalitet generisanih slika, stabilnost treniranja i kontrolu nad procesom generisanja. Tokom godina, predložen je veliki broj GAN modela, pri čemu su se neki izdvojili kao posebno značajni zbog svoje praktične primjene u generisanju slika. U ovom poglavlju prikazani su najčešće korišćeni GAN modeli koji su obilježili razvoj oblasti i koji su relevantni za probleme sinteze vizuelnih podataka.

Jedna od prvih i najuticajnijih varijanti je **Deep Convolutional GAN (DCGAN)**, koji uvodi sistematsku upotrebu konvolucionih neuronskih mreža u arhitekturu generatora i diskriminatora. Umjesto klasičnih potpuno povezanih slojeva, DCGAN koristi konvolucije i dekonvolucije, čime se omogućava efikasnije učenje prostorne strukture slika. DCGAN se često smatra polaznom tačkom za savremene GAN eksperimente na slikama, jer kombinuje relativnu jednostavnost sa dobrim performansama.


Dalji razvoj GAN modela doveo je do uvođenja **Conditional Generative Adversarial Networks (cGAN)**. Ove mreže predstavljaju proširenje osnovnog GAN modela, u kojem se dodatne informacije u vidu oznaka (*labela*) uvode kao uslov i za generator i za diskriminator (*Slika 7*). Ove oznake omogućavaju kontrolisano generisanje podataka, jer usmjeravaju generator ka stvaranju uzoraka sa određenim karakteristikama, dok diskriminator koristi iste informacije kako bi preciznije razlikovao stvarne i generisane podatke. Na taj način, cGAN modeli postižu bržu konvergenciju i efikasnije učenje u poređenju sa neuslovljenim GAN pristupima.



Slika 7: Conditional GAN

Posebno značajan pravac razvoja predstavljaju GAN modeli za **transformaciju slike-u-sliku**, među kojima se ističu **pix2pix** i **CycleGAN** pristupi. Pix2pix modeli su namijenjeni situacijama u kojima postoje upareni ulazno-izlazni podaci, te omogućavaju učenje preslikavanja između dva vizuelna domena. Nasuprot tome, CycleGAN uvodi koncept ciklične konzistentnosti, čime omogućava učenje transformacija između domena i u odsustvu uparenih podataka. Ovi modeli su pokazali da se adversarijalno učenje može koristiti ne samo za generisanje novih slika, već i za realističnu vizuelnu transformaciju postojećih.

Posebno napredan pristup u okviru generativnih adversarijalnih mreža predstavlja **StyleGAN arhitektura** (Slika 8), koja uvodi koncept razdvajanja stilskih komponenti tokom procesa generisanja slike. Umjesto direktnog mapiranja latentnog vektora na izlaznu sliku, StyleGAN omogućava kontrolu različitih nivoa vizuelnih karakteristika, pri čemu se globalna struktura objekta, srednji elementi i fini detalji modeluju na različitim slojevima mreže. Ovakav pristup omogućava kombinovanje vizuelnih osobina iz različitih uzoraka, što je posebno interesantno za domene poput LEGO figurica, gdje se mogu razdvajati i kombinovati oblik figurice, stil odjeće i kolorni detalji, uz zadržavanje koherentne strukture generisanog objekta.



Pored navedenih modela, u literaturi se pojavljuju i brojne druge varijante GAN-ova koje se fokusiraju na specifične aspekte problema, kao što su stabilnost treniranja, raznovrsnost generisanih uzoraka ili efikasnost učenja. Ipak, DCGAN, cGAN, CycleGAN i StyleGAN predstavljaju ključne tačke razvoja GAN pristupa za slike i često služe kao referentni modeli u savremenim istraživanjima. Razumijevanje njihovih osnovnih principa i razlika pruža solidnu osnovu za izbor odgovarajućeg modela u konkretnim primjenama generisanja slika.

5. Skupovi podataka, metrike i ograničenja

Kao i drugi modeli, tako i evaluacija generativnih adversarijalnih mreža u velikoj mjeri zavisi od kvaliteta i karakteristika skupa podataka na kojem se trenira. Kada govorimo o generisanju slika, u literaturi se često koriste standardni skupovi podataka kao što su *MNIST*, *CIFAR-10* i *CelebA*, koji omogućavaju poređenje različitih pristupa u kontrolisanim uslovima. Pored ovih skupova, značajnu ulogu imaju i prilagođeni skupovi podataka, naročito u slučajevima kada se model primjenjuje na specifične vizuelne domene, poput slika LEGO figurica.

Za procjenu kvaliteta generisanih slika koriste se različite metrike, među kojima se najčešće navode **Inception Score (IS)** i **Fréchet Inception Distance (FID)**. Ove metrike nastoje da kvantitativno ocijene sličnost između stvarnih i generisanih podataka, ali se u praksi često kombinuju sa subjektivnom vizuelnom procjenom, budući da numeričke vrijednosti ne moraju uvijek u potpunosti odražavati perceptivni kvalitet slika.

Uprkos stalnom unapređivanju, GAN modeli se i dalje suočavaju sa određenim ograničenjima. Najčešći izazovi uključuju nestabilnost tokom treniranja, pojavu mode collapse fenomena, kao i osjetljivost na izbor arhitekture i hiperparametara. Ova ograničenja ukazuju na potrebu pažljivog dizajna eksperimentalnog okvira i predstavljaju važan motiv za dalje istraživanje i unapređenje generativnih modela.

6. Vizija i komentar

Na osnovu pregleda teorijskih osnova i postojeće literature, generativne adversarijalne mreže mogu se posmatrati kao snažan i fleksibilan okvir za generisanje vizuelnih podataka. Dosadašnja istraživanja pokazuju da GAN modeli nisu ograničeni samo na sintezu slika visoke vizuelne kvalitete, već omogućavaju i kontrolisano generisanje, manipulaciju vizuelnim atributima i kombinovanje karakteristika iz različitih uzoraka. Ovakve osobine čine GAN pristup posebno pogodnim za primjenu na domenima koji posjeduju jasnu strukturu, ali i visok stepen varijabilnosti.

Posebno interesantan aspekt problema predstavlja činjenica da se slike LEGO figurica mogu grupisati prema tematskim cjelinama, pri čemu pojedine grupe dijele zajedničke

vizuelne karakteristike, poput odjeće, boja i prepoznatljivih detalja. Takva struktura podataka otvara mogućnost istraživanja kontrolisanog generisanja slika, gdje bi model mogao da nauči razlike između različitih vizuelnih domena i generiše uzorke koji odgovaraju zadatoj temi. Na primjer, figurice iz istog tematskog univerzuma mogu posjedovati zajednički vizuelni stil, što omogućava ispitivanje sposobnosti generativnog modela da internalizuje i reprodukuje ove karakteristike.

Ovaj projekat predstavlja priliku za dublje razumijevanje generativnih modela i izazova koji prate njihovu praktičnu primjenu. Pored samog generisanja slika, značajan aspekt rada predstavlja i analiza ograničenja GAN modela, poput stabilnosti treniranja i raznovrsnosti generisanih rezultata.

Stečena teorijska osnova predstavlja temelj za dalji rad na ovom projektu, koji će u narednim kontrolnim tačkama biti usmjeren na implementaciju odabranog modela i analizu dobijenih rezultata. Na taj način, projekat će povezati teorijsko razumijevanje generativnih adversarijalnih mreža sa njihovom praktičnom primjenom u konkretnom vizuelnom domenu.

ANALIZA DOBIJENIH REZULTATA

7. Opis sprovedenog eksperimenta

U ovom radu je implementiran **DCGAN (Deep Convolutional Generative Adversarial Network)** sa ciljem generisanja sintetičkih slika LEGO minifigura. Izbor DCGAN arhitekture je motivisan njenom sposobnošću da efikasno modeluje prostorne korelacije u slikama korišćenjem konvolucionih slojeva, što je naročito važno kod vizuelno strukturiranih objekata kao što su LEGO figure.

Dataset LEGO_GAN_AUG, pripremljen u Kontrolnoj tački 2, sastoji se od približno 2000 slika raspoređenih u četiri tematske klase (Harry Potter, Jurassic World, Marvel i Star Wars), sa približno ujednačenim brojem uzoraka po klasi. Slike su skalirane na rezoluciju 64×64 piksela i normalizovane u opseg $[-1, 1]$, što omogućava stabilan trening Generatora sa Tanh izlaznom aktivacijom.

DCGAN se sastoji od dva konkurentna modela:

- **Generator**, koji mapira latentni vektor šuma u prostor slika,
- **Diskriminator**, koji procenjuje da li je ulazna slika realna ili generisana.

Za razliku od klasičnih supervised modela, ovdje ne postoji jedinstvena funkcija cilja. Trening predstavlja min–max igru, u kojoj Generator pokušava da minimizira sposobnost Diskriminatora da razlikuje uzorke, dok Diskriminator nastoji da maksimizira tu sposobnost. Zbog toga se kvalitet modela ne može procenjivati izolovano preko jedne metrike, već kroz kombinaciju stabilnosti treninga, ponašanja diskriminatora, kvantitativnih metrika i kvalitativne (vizuelne) analize.

Uzorci pravih slika iz train dataseta



Slika 1: Uzorci pravih slika iz augmetnovanog data seta LEGO_GAN_AUG

8. Odabir metrika i njihova interpretacija u kontekstu GAN-a

Evaluacija GAN modela zahtijeva drugačiji način razmišljanja u odnosu na klasične probleme klasifikacije ili regresije. U idealnom slučaju, diskriminator **ne treba da bude savršen**, jer bi to značilo da Generator nije naučio distribuciju podataka.

U tom smislu:

- **Loss krive Generatora i Diskriminatora** služe prvenstveno za praćenje dinamike treninga, detekciju nestabilnosti, kolapsa ili prevelike dominacije jednog od modela.
- **Accuracy Diskriminatora** se ne interpretira kao „što više, to bolje“, već se vrijednosti bliske 50% smatraju indikacijom postignute adversarijalne ravnoteže.
- **Klasifikacione metrike na test skupu (Accuracy, Precision, Recall, F1, ROC-AUC)** koriste se isključivo kao pomoćni signal, koji kvantitativno potvrđuje da Diskriminator gubi sposobnost pouzdanog razlikovanja realnih i generisanih slika.
- **FID (Fréchet Inception Distance)** predstavlja ključnu kvantitativnu metriku kvaliteta, jer poredi distribucije realnih i generisanih slika u prostoru dubokih semantičkih karakteristika.
- **Latentna interpolacija** omogućava kvalitativnu procjenu strukture latentnog prostora i provjeru da li Generator uči kontinuiranu distribuciju, a ne memorisane primjere.

Ovakav višeslojni skup metrika omogućava holističku evaluaciju GAN modela, pri čemu se nijedan rezultat ne posmatra izolovano.

9. Analiza procesa treniranja i stabilnosti modela

9.1 Loss krive (train vs validation)


Analiza loss krivih pokazuje tipičnu **cikličnu dinamiku GAN modela**. U ranim fazama treninga Diskriminator brzo uči da razlikuje realne i lažne slike, što dovodi do njegove privremene dominacije. Posljedično, Generator u tim fazama ima otežano učenje.

Međutim, kako trening napreduje, Generator postepeno poboljšava kvalitet generisanih uzoraka, što dovodi do ponovnog uspostavljanja ravnoteže. Ovakva dinamika je očekivana i u skladu je sa teorijskim opisima GAN treninga.


U završnoj fazi treninga (poslednjih ~60 epoha), train i validation loss vrijednosti ostaju bliske:

- Generator loss: 0.5266 (train) / 0.5099 (val)
- Discriminator loss: 1.4056 (train) / 1.4749 (val)

Minimalna razlika između trening i validacionih krivih ($\approx 3\text{--}5\%$) ukazuje na odsustvo izraženog overfitting-a. Model ne memoriše pojedinačne uzorke, već uči opštu distribuciju podataka, što je posebno važno kod generativnih modela (*Slika 3*).



Slika 2 – Train i Validation loss kroz epohe



Slika 2 – Generator i Discriminator loss tokom treninga i validacije


9.2 Accuracy diskriminatora i adversarijalna ravnoteža

Za razliku od klasičnih klasifikacionih problema, visoka accuracy diskriminatora u GAN-u predstavlja negativan signal, jer ukazuje na slab Generator. Idealno stanje predstavlja situacija u kojoj Diskriminator pogađa približno nasumično.


U završnoj fazi treninga dobijene su sljedeće vrijednosti:

- D Accuracy (Real): **52.40%**
- D Accuracy (Fake): **55.01%**
- Ukupna accuracy: **53.71%**

Ovi rezultati ukazuju da je postignuto stanje blisko **adversarijalnoj ravnoteži**, gdje Diskriminator više ne može pouzdano razlikovati realne i generisane slike (*Slika 4*).



Slika 4 - Accuracy diskriminatora (Real/Fake) kroz epohe



Slika 5 - Progresija generisanih slika kroz faze treninga

10. Test evaluacija diskriminatora

Kako bi se kvantitativno potvrdila sposobnost Generatora da proizvodi uvjerljive slike, Diskriminator je evaluiran na test skupu kao binarni klasifikator. Dobijeni rezultati su:

- Accuracy: **48.71%**
- Precision: **0.4845**
- Recall: **0.9367**


- F1-score: **0.6386**
- ROC-AUC: **0.6416**

Niska ukupna tačnost i relativno visok recall za real klasu ukazuju da Diskriminator često pogrešno klasifikuje generisane slike kao realne. U GAN kontekstu, ovo predstavlja poželjan ishod, jer implicira da Generator proizvodi uzorke koji su teško razlikljivi od stvarnih.

Ovakvi rezultati ukazuju da model nije naučio specifične obrasce vezane isključivo za trening skup, već da generisane slike zadržavaju sličnosti sa realnim podacima i izvan skupa na kojem je treniran. Ovo je posebno značajno u kontekstu malog dataseta, gdje je rizik od overfitting-a izraženiji nego kod velikih skupova podataka. Test evaluacija dodatno potvrđuje da adversarijalna ravnoteža postignuta tokom treninga nije narušena pri prelasku na neviđene primjere. Na taj način, rezultati testiranja služe kao važan indikator stabilnosti i robusnosti treniranog Generatora.

Metrika	Vrijednost	Interpretacija u kontekstu GAN-a
Accuracy	48.71%	D pogađa gore od bacanja novčića – slike nerazlučive
Precision	0.4845	Kad D kaže "pravo", u pola slučajeva griješi
Recall	0.9367	D skoro sve proglašava "pravim" jer su lažne ubjedljive
F1-Score	0.6386	Umjeren – D se aktivno muči da razlikuje
ROC-AUC	0.6416	Blizu 0.5 – skoro nema moći razlikovanja

Tabela 1 - Interpretacija rezultata na test skupu




Slika 6 - Matrica konfuzije (Confusion matrix)

11. Kvalitativna analiza: vizuelni rezultati i latentni prostor

11.1 Poređenje realnih i generisanih slika

Vizuelna inspekcija pokazuje da Generator uspijeva da nauči **globalne karakteristike** slika (centralna figura, osnovne boje i raspored), ali da finiji detalji i teksture ostaju ograničeni. Ovakav rezultat je u skladu sa relativno visokim FID skorom i ograničenjima dataseta.

Vizuelna analiza je naročito važna kod generativnih modela, jer pojedini aspekti kvaliteta slike ne mogu biti u potpunosti obuhvaćeni numeričkim metrikama. Iako generisane slike ne dostižu nivo fotorealističnosti, jasno je da one sadrže semantički smislen sadržaj i prepoznatljivu strukturu objekata. Prisustvo zamućenja i artefakata ukazuje na ograničenja modela u pogledu učenja finih detalja, ali ne umanjuje činjenicu da je naučena osnovna distribucija oblika i boja. Ovakvi rezultati su u skladu sa teorijskim očekivanjima za DCGAN treniran na ograničenom broju uzoraka.



7 - Poređenje pravih i generisanih slika

Slika

11.2 Interpolacija u latentnom prostoru

Interpolacija između dvije latentne tačke pokazuje glatke i postepene promjene u generisanim slikama, bez naglih diskontinuiteta ili kolapsa strukture (*Slika 8*). Ovo ukazuje da latentni prostor Generatora ima **kontinuiranu i smisleno organizovanu strukturu**, što sugeriše da model uči distribuciju podataka, a ne memorisane uzorke.

Smisleno organizovan latentni prostor je jedan od ključnih pokazatelja uspješnog generativnog modelovanja. Glatke tranzicije između uzoraka ukazuju da Generator nije naučio diskretne ili izolovane reprezentacije pojedinačnih slika. Umjesto toga, model je uspio da uhvati kontinuirane faktore varijacije prisutne u podacima, kao što su promjene boja, položaja i osnovne forme objekata. Ovakvo ponašanje latentnog prostora dodatno potvrđuje da se ne radi o memorisanju trening podataka, već o učenju opšte strukture distribucije.



Slika 8 - Interpolacija u latentnom prostoru

12. FID metrika i njeno značenje

Izračunati **FID score iznosi 199.33**, što ukazuje da distribucija generisanih slika i dalje značajno odstupa od realne distribucije. Iako je ova vrijednost visoka u apsolutnom smislu, ona je očekivana za dataset ove veličine i raznolikosti. U ovom radu FID se koristi prvenstveno kao **relativna metrika**, za poređenje različitih eksperimenata, a ne kao apsolutni pokazatelj kvaliteta. Rezultati dobijenih FID score vrijednosti u zavisnosti od veličine dataseta se mogu vidjeti u tabeli ispod (*Tabela 2*).

Dobijeni FID Score: 199.33		
FID raspon	Kvalitet	Tipičan kontekst
< 10	Izvanredan	StyleGAN2, milioni slika
10–50	Vrlo dobar	Veliki dataseti (50k+ slika)
50–100	Dobar	Srednji dataseti
100–200	Umjeren	Mali dataseti – naš slučaj
200–300	Slab	Nedovoljno treniran model
300+	Loš	Model ne funkcioniše

Tabela 2 - Dobijeni FID score

13. Analiza po klasama i ograničenja modela

Iako dataset sadrži više tematskih klasa, korišćeni DCGAN model nije uslovljen klasnim informacijama. Zbog toga Generator uči objedinjenu distribuciju svih klasa, bez eksplicitne kontrole nad klasom generisanog uzorka, što otežava direktnu analizu rezultata po pojedinačnim klasama. Ovo predstavlja važno ograničenje primijenjenog modela, naročito u kontekstu višeklasnih skupova podataka.

Dodatna post-hoc analiza, zasnovana na klasifikaciji generisanih slika, može pružiti indicaciju o tome da li Generator implicitno pokriva sve klase ili pokazuje sklonost ka

određenim vizuelnim obrascima. Međutim, ovakva analiza u velikoj mjeri zavisi od kvaliteta pomoćnog klasifikatora i ne može u potpunosti zamijeniti uslovni GAN pristup.


Pored arhitekturnih ograničenja, značajan faktor predstavlja i relativno mala veličina dataseta (~2000 augmentovanih slika) za potrebe stabilnog višeklasnog generativnog modelovanja. Ograničen broj uzoraka po klasi može dovesti do toga da Generator lakše uči dominantne ili vizuelno jednostavnije obrasce, dok kompleksnije klase ostaju slabije reprezentovane u generisanim uzorcima. Ovakva kombinacija malog dataseta i neuslovljenog modela dodatno povećava rizik od implicitne pristrasnosti ka određenim klasama.

Zbog navedenih razloga, analiza po klasama u ovom radu ima prvenstveno dijagnostičku i motivacionu ulogu, dok bi za preciznu i kontrolisanu sintezu po klasama bilo neophodno primijeniti uslovne GAN arhitekture (npr. cGAN ili ACGAN), uz značajno veći i raznovrsniji skup podataka.

14. Pokušaj poboljšanja: WGAN-GP

Na osnovu teorijskih prednosti Wasserstein GAN modela, implementiran je i **WGAN-GP** kao pokušaj poboljšanja stabilnosti i kvaliteta generisanih slika. Očekivanje je bilo da Wasserstein loss i gradient penalty obezbijede stabilnije gradijente i bolju konvergenciju.

Međutim, eksperimentalni rezultati nisu pokazali poboljšanje. Tokom treninga Critic je pokazivao ekstremno neuravnoteženo ponašanje ($\text{Accuracy_real} \approx 100\%$, $\text{Accuracy_fake} \approx 0\%$), što ukazuje na degenerisanu adversarijalnu dinamiku. Dodatno, FID skor se pogoršao na **268.78**, a vizuelni kvalitet generisanih slika bio je lošiji u odnosu na DCGAN.



Slika 8 – Primjeri slika generisanih WGAN-GP modelom

SUMARNA TABELA REZULTATA				
Metrika		Vrednost		
Generator Loss (finalna)		-118.9211		
Discriminator Loss (finalna)		-0.9133		
Val Generator Loss (finalna)		-118.5713		
Val Discriminator Loss (finalna)		-0.6579		
D Accuracy (Real)		100.00%		
D Accuracy (Fake)		0.00%		
D Accuracy (Ukupna)		50.00%		
Test Accuracy		48.39%		
Test Precision		0.4839		
Test Recall		1.0000		
Test F1-Score		0.6522		
Test ROC-AUC		0.5541		
FID Score		268.78		
Epoha	G Loss	D Loss	Acc Real	Acc Fake
1	-11.6685	34.3645	91.35%	0.65%
126	-28.6183	0.1978	100.00%	0.00%
251	-60.8537	-0.5267	100.00%	0.00%
376	-92.6892	-0.4172	100.00%	0.00%
500	-118.9211	-0.9133	100.00%	0.00%

Tabela 3 – Sumarna tabela rezultata WGAN-GP

Metrika / Aspekt	DCGAN (finalni model)	WGAN-GP (pokušaj poboljšanja)
Tip modela	Klasični DCGAN	Wasserstein GAN sa Gradient Penalty
Loss funkcija	Binary Cross-Entropy	Wasserstein loss + GP
Stabilnost treninga	Stabilan u završnoj fazi	Numerički stabilan, ali degenerisan
Dinamika treninga	Ciklična, sa završnim balansom	Dominacija Critic-a kroz cijeli trening
D / Critic Accuracy (Real)	~52%	~100%
D / Critic Accuracy (Fake)	~55%	~0%
Ukupna Accuracy (train)	~54%	~50% (trivijalna)
Test Accuracy	48.7%	48.4%
Test Precision	0.48	0.48
Test Recall	0.94	1.00
Test F1-score	0.64	0.65
Test ROC-AUC	0.64	0.55
FID Score ↓	199.33	268.78
Vizuelni kvalitet	Prepoznatljiva globalna struktura	Strukturalno degradirane slike
Latentni prostor	Kontinuiran i smislen	Slabo iskorišten
Adversarijalni balans	Postignut u završnoj fazi	Nije postignut
Konačna odluka	Zadržan kao finalni model	Odbačen

Tabela 4 – Poređenje DCGAN i WGAN-GP modela

15. Zaključak i budući pravci rada

Na osnovu sprovedenih eksperimenata može se zaključiti da je DCGAN model djelimično uspješno implementiran i istreniran, te da je postigao stabilan adversarijalni balans u okviru realnih ograničenja dostupnog dataseta. Analiza loss krivih, accuracy Diskriminatora i test metrika pokazuje da je Generator naučio osnovnu distribuciju podataka i da proizvodi vizuelno koherentne slike koje Diskriminator ne može pouzdano razlikovati od realnih. Odsustvo značajnog odstupanja između trening i validacionih rezultata dodatno potvrđuje da model ne pati od izraženog overfitting-a, već generalizuje naučene obrasce.

Eksperimentalni pokušaj unapređenja modela primjenom WGAN-GP arhitekture pokazao je da napredniji algoritam sam po sebi ne garantuje bolje rezultate. Iako WGAN-GP teorijski nudi stabilnije gradijente i bolju konvergenciju, u konkretnoj postavci sa malim i heterogenim datasetom nije došlo do poboljšanja kvaliteta generisanih slika, što potvrđuju i lošiji FID skorovi i ponašanje kritičara. Ovi rezultati ukazuju da izbor arhitekture mora biti usklađen sa količinom i strukturom podataka, te da složeniji modeli mogu čak pogoršati rezultate ukoliko nisu podržani adekvatnim datasetom.

Jedan od ključnih nalaza ovog rada jeste da veličina i kvalitet dataseta predstavljaju dominantan faktor uspjeha GAN modela, često značajniji od same arhitekture ili optimizacionih tehnika. Mali broj uzoraka po klasi, u kombinaciji sa neuslovljenim generativnim pristupom, ograničava sposobnost modela da nauči fine detalje i ravnomjerno pokrije sve tematske varijacije prisutne u podacima. Ova ograničenja jasno se reflektuju u vizuelnoj analizi i kvantitativnim metrikama.

Budući pravci rada mogu uključiti proširenje i homogenizaciju dataseta, što predstavlja najdirektniji način za unapređenje kvaliteta generisanih slika. Dodatno, primjena uslovnih GAN arhitektura (cGAN, ACGAN) omogućila bi kontrolisano generisanje slika po klasama i precizniju evaluaciju rezultata. Povećanje rezolucije slika, kao i korišćenje savremenijih modela poput StyleGAN-a ili Progressive GAN-a, uz adekvatno veći skup podataka, vjerovatno bi dovelo do značajnog poboljšanja vizuelnog kvaliteta i realističnosti generisanih uzoraka.

Na kraju, ovaj rad pokazuje da je stabilan i smislen GAN trening moguć čak i na relativno malom datasetu, ali i jasno demonstrira granice takvog pristupa. Dobijeni rezultati pružaju solidnu osnovu za dalja istraživanja i predstavljaju vrijedan eksperimentalni uvid u odnos između arhitekture, podataka i metrika u generativnom modelovanju slika.

16. Literatura

- [1] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville i Y. Bengio, "Generative Adversarial Networks," *Advances in Neural Information Processing Systems (NeurIPS)*, 2014.
- [2] A. Radford, L. Metz i S. Chintala, "Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks," *International Conference on Learning Representations (ICLR)*, 2016.
- [3] J. Zhu, T. Park, P. Isola i A. A. Efros, "Unpaired Image-to-Image Translation using CycleConsistent Adversarial Networks," *International Conference on Computer Vision (ICCV)*, 2017.
- [4] T. Karras, S. Laine i T. Aila, "A Style-Based Generator Architecture for Generative Adversarial Networks," *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019.
- [5] "Overview of GAN Structure," Google Developers, Machine Learning, 2025. [Online]. Available: https://developers.google.com/machine-learning/gan/gan_structure
- [6] "What is a Conditional Generative Adversarial Network (cGAN)?," DataScientest, 2025. [Online]. Available: <https://datascientest.com/en/what-is-a-conditional-generative-adversarialnetwork-cgan>
- [7] "Discover NVIDIA's StyleGAN: Revolutionary Image Generation," Viso.ai, Deep Learning Insights, 2025. [Online]. Available: <https://viso.ai/deep-learning/stylegan/>
- [8] "22.2-GAN Theory," University at Buffalo, 2025. [Online]. Available: <https://cedar.buffalo.edu/~srihari/CSE676/22.2-GAN%20Theory.pdf>
- [9] "Pix2pix: Key Model Architecture Decisions," Neptune.ai, 2025. [Online]. Available: <https://neptune.ai/blog/pix2pix-key-model-architecture-decision>